Entrega 1

Modelos Estadísticos para la clasificación y regresión

21 de septiembre de 2026

Se deberá entregar un documento en formato .pdf que contendrá el nombre y cédula de los **tres** integrantes del grupo, un link a un repositorio (o link de colab, carpeta de drive) donde se puedan ver los códigos utilizados, y una carilla a cada uno de los problemas planteados. El .pdf podrá por lo tanto contener a lo sumo 4 carillas.

Para cada problema se debe presentar qué conclusiones sacaron a partir del problema planteado. El grupo elegirá qué presisan incluir (gráficas, tablas) para soportar sus conclusiones. No se debe incluir una respuesta por ítem planteado, sino que se itemiza como guía para analizar los problemas. El tercer problema depende de la calidad de los datos recabados, por lo que es posible que no lleguen a modelos que los convenzan, la idea de este ejercicio es trabajar con un problea con datos reales y sin curar y que ustedes tomen sus propias decisiones.

La fecha de entrega es el *12 de octubre*, y se debe realizar en grupos de a 3. Los nombres deberán estar en el archivo enviado. Alcanza con que lo envíe una persona por grupo.

1. Estimador de máxima verosimilitud

Sea X una v.a. tal que $f_X(x) = \frac{1}{2}(1 + \theta x)$ si $1x1$, con $\theta \in [1, 1]$.

1. Escribir una función para simular una muestra de tamaño n suponiendo $\theta = -1/3$.
2. Para una muestra de tamaño 10, graficar la función de máxima verosimilitud y aproximar el máximo para estimar θ (mínimo en caso de usar el log verosimilitud). Para hacerlo se puede implementar un algoritmo como *Golden search* o usar una función auxiliar que lo haga.
3. Generar muchas muestras de tamaño 10, (del orden de 50) y estimar para cada muestra el varlor de θ. Sabiendo que el $\theta = -1/3$ calcular MSE, sesgo y varianza.
4. Realizar el mismo procedimiento de la parte anterior, pero con muestras de tamaño 100 y 1000.

Analizar cómo cambian el MSE, sesgo y varianza del estimador.

2. Regresión en el Conjunto de Datos "Boston Housing"

El conjunto de datos "Boston Housing" es un clásico en machine learning y estadística. Contiene información recopilada por el Servicio de Censos de EE.UU. sobre viviendas en el área de Boston. El dataset contiene 506 observaciones y 13 atributos que pueden influir en el valor mediano de las viviendas en Boston.

Objetivo: Predecir el valor mediano de las viviendas (MEDV) usando atributos como la tasa de criminalidad (CRIM), la cantidad promedio de habitaciones por vivienda (RM), entre otros.

1. Carga y Análisis Inicial: Carga el conjunto de datos "Boston Housing" y realiza un análisis exploratorio inicial.

2. Preprocesamiento: Divide el conjunto de datos en conjuntos de entrenamiento y validación.

3. Modelo Lineal: Entrena una regresión lineal usando todas las características para predecir MEDV. Evalúa su rendimiento en los conjuntos de entrenamiento y validación usando el error cuadrático medio (MSE).

4. Modelo Polinomial: Considera las características polinomiales hasta grado 3. Entrena el modelo y evalúa su rendimiento.

5. Regularización: Usa la regresión Ridge con las características polinomiales. Encuentra el valor óptimo de λ usando validación cruzada.

Gráficas sugeridas: Grafica la evolución del MSE en función del grado del polinomio. Grafica el MSE en función de λ para Ridge. Visualiza el mejor modelo polinomial con y sin regularización en comparando las predicciones con los datos reales.

Conclusiones: ¿qué modelo considerarías el mejor? ¿Cómo impactan las características polinomiales y la regularización en el rendimiento del modelo?

3. Alturas

A partir del juego de datos alturas recabado en clase, realizar un modelo lineal para predecir la altura de los hijos. En este ejercicio deberás tomar las decisiones que te parezcan adecuadas y contarnos tus conclusiones, es decir, no es olbigatorio usar todos los datos, ni todas las variables. Una vez elegido el modelo, escribirlo y explicar qué significa cada uno de sus coeficientes.