Segunda entrega Modelos Estadísticos para la Clasificación y Regresión

Se debe entregar un informe a partir de las preguntas orientativas, es decir, no se debe contestar cada pregunta, sino redactar como si fuera un informe, para que un lector que no sabe las preguntas guía entienda lo planteado. El largo máximo del informe es de 3 carillas. Se debe agregar un link al código utilizado que debe ester en un notebook, colab o similar.

Sobre uso de IA para la entrega: Está permitido usar IA para generar código, pero los análisis, qué hacer y las conclusiones deben ser propias. No está permitido el uso de IA para redactar el informe. En el informe se debe indicar si usaron IA, y cómo y para qué la usaron.

El objetivo de esta tarea es entrenar y comparar distintos modelos de regresión sobre datos sintéticos, y analizar cómo se comportan las predicciones cuando los datos provienen de una distribución ligeramente diferente.
El conjunto de datos sobre el que realizaremos las predicciones estará formado por dos subconjuntos. El primero proviene de la misma distribución que los datos de entrenamiento, mientras que el segundo será similar, pero se generará sumando una constante, generada de manera aleatoria, a todas las variables, lo que modificará la media de su distribución. Debido a esta diferencia, esperamos que el modelo obtenga errores pequeños al predecir sobre el primer subconjunto y errores más grandes sobre el segundo. En un caso real, no siempre tenemos la información sobre cómo fueron generados los conjuntos, ni que existe este desplazamiento en los datos. Por ello, una buena estrategia para detectar y entender este tipo de comportamientos es aplicar un Análisis de Componentes Principales (PCA), que permite visualizar las relaciones y diferencias entre ambos subconjuntos en el espacio de las variables.

1) Generar un conjunto de datos sintético con 150 observaciones y 50 variables (X_1, X_2, …, X_{50}). Las variables deben tener correlaciones no nulas entre sí. Para lograrlo, utilizar una matriz de correlaciones (provista en el EVA) y generar los datos con una distribución normal multivariada.
2) Definir una variable objetivo Y como combinación lineal de las 50 variables, donde solo 5 serán informativas (tendrán coeficientes no nulos). Agregar un pequeño ruido aleatorio gaussiano con media cero y poca varianza (por ejemplo, 0.25).
3) Separar los datos en:
    - Conjunto de entrenamiento: 100 observaciones
    - Conjunto de test: 50 observaciones
4) Entrenar cuatro modelos distintos utilizando el conjunto de entrenamiento: 3 usando todas las variables, regresión lineal simple, regresión Ridge, regresión Bayesiana y uno eligiendo las primeras componentes principales (cuántas componentes elegir es parte del ejercicio) y luego haciendo una regresión lineal simple. Graficar los coeficientes (pesos) estimados para cada una de las 50 variables (como en el laboratorio 4), para la regresión de PCA, investigar cómo hacerlo, usando los pesos de cada variable en la componente. Comparar los resultados y comentar respecto a

las variables que sabemos que contienen información. Elegir uno de los modelos para continuar, justificando la elección.

5) Aplicar un análisis de componentes principales (PCA) al conjunto de entrenamiento. Graficar las dos primeras componentes principales (PC1 y PC2) para visualizar la estructura de los datos.
6) Dividir el conjunto de test en dos subconjuntos iguales:
    - A: 25 observaciones
    - B: 25 observaciones

    Generar un vector aleatorio de tamaño 50 (por ejemplo, con valores uniformes entre -5 y 5) y sumarlo a todas las filas del conjunto A. De esta manera, el conjunto A representará datos provenientes de una distribución desplazada, mientras que B mantendrá la distribución original.

7) Usar el modelo elegido en la parte 2 para predecir sobre ambos conjuntos (A modificado y B). Calcular el error de predicción en cada observación y el error cuadrático medio en cada uno de los conjuntos. Comentar los resultados.
8) Proyectar los conjuntos A y B en el espacio de las componentes principales obtenidas en la parte 3 y graficar las proyecciones (PC1 vs PC2), coloreando los puntos según el error de predicción. Comentar los resultados.
9) Si no conociera las constantes que se le sumaron a las variables del conjunto A, ¿qué estrategia elegiría para mejorar las predicciones en ese conjunto?